

Продвинутая линейная алгебра



Типы матриц. Собственные вектора и собственные значения. Матричные разложения. Приближение матрицей меньшего ранга. Сингулярное разложение и низкоранговое приближение.

Даниил Корбут

Специалист по Анализу Данных



Даниил Корбут
DL Researcher
Insilico Medicine, Inc

Окончил бакалавриат ФИВТ
МФТИ (Анализ данных) в 2018г
Учусь на 2-м курсе
магистратуры ФИВТ МФТИ
Работал в Statsbot и Яндекс.
Алиса.
Сейчас в Insilico Medicine, Inc,
занимаюсь генерацией
активных молекул и
исследованиями старения с
помощью DL.

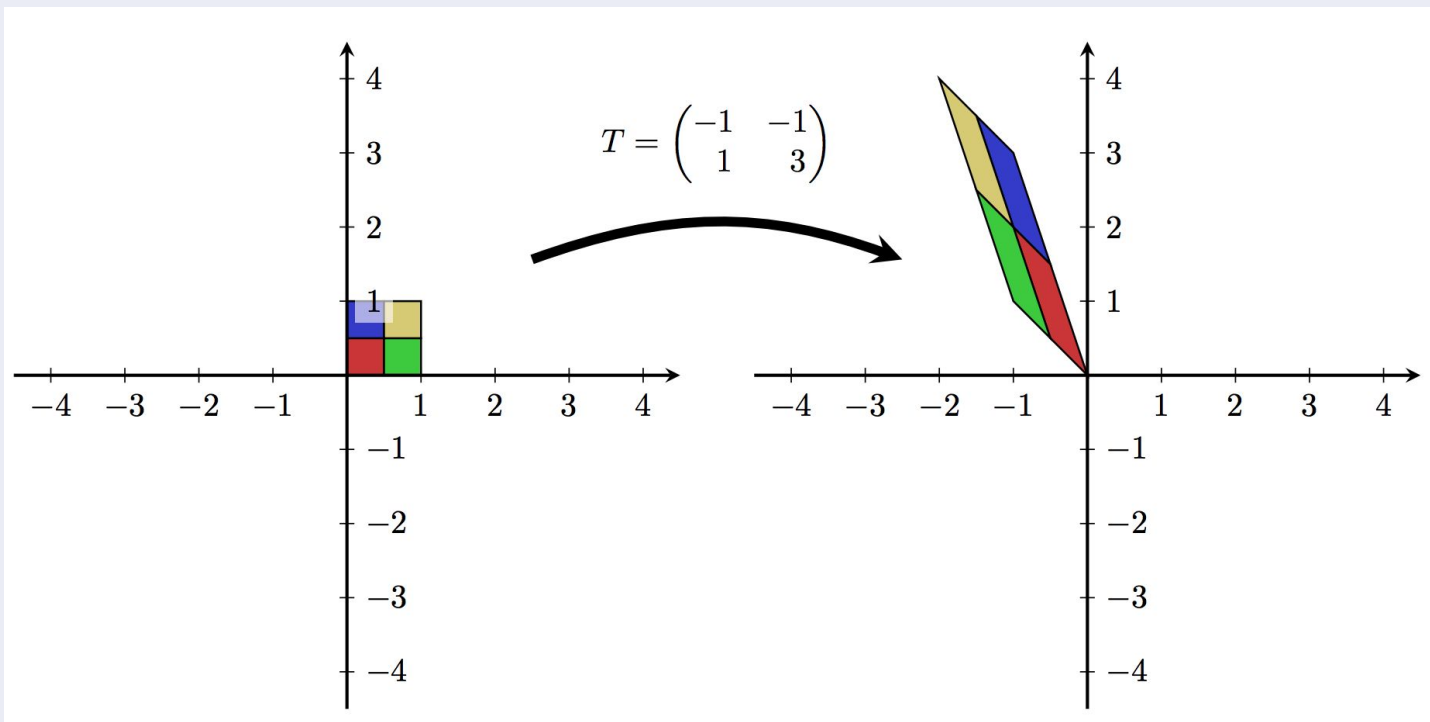
Типы матриц

$$A_{m \times n} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \cdot & \cdot & \cdot & \cdot \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}$$


1. $m=n \Rightarrow$ квадратная, иначе прямоугольная
2. $m = 1 \Rightarrow$ матрица-строка
3. $n=1 \Rightarrow$ матрица-столбец
4. нулевая матрица, если все элементы = 0
5. диагональная (единичная)
6. треугольная(нижнетреугольная, верхнетреугольная)
7. ортогональная

$$AA^T = A^T A = E$$


Типы матриц (преобразование пространства)





Типы матриц (преобразование пространства)



Типы матриц (преобразование пространства)



Собственные векторы и собственные значения



Собственный вектор преобразования A

$$AX = \lambda X$$

X - собственный вектор (ненулевой!)
 λ - собственное значение


!

У матрицы $n \times n$ не более n собственных значений

<https://ru.wikipedia.org>

Собственные векторы и собственные значения: применение

1. Собственные векторы - направления, в которых матрица лишь растягивает или сжимает векторы, но не поворачивает
2. Показывают направления наибольшего изменения
3. Возникают при уменьшении размера матрицы



Собственные вектора и собственные значения (поиск)

$$A - \lambda E$$

характеристическая матрица матрицы **A**

$$|A - \lambda E|$$

характеристический многочлен матрицы **A**

$$|A - \lambda E| = 0$$

характеристическое уравнение матрицы **A**



Теорема. Собственными числами матрицы **A** являются корни характеристического уравнения матрицы **A** и только они.

Собственные вектора и собственные значения (пример)

$$\begin{array}{c} A = \begin{pmatrix} -1 & -6 \\ 2 & 6 \end{pmatrix} \rightarrow \begin{vmatrix} -1-\lambda & -6 \\ 2 & 6-\lambda \end{vmatrix} = 0 \\ \downarrow \quad \lambda^2 - 5\lambda + 6 = 0 \quad \downarrow \\ \begin{cases} -4x - 6y = 0 \\ 2x + 3y = 0 \end{cases} \quad \begin{cases} \lambda_1 = \frac{5-1}{2} = 2 \\ \lambda_2 = \frac{5+1}{2} = 3 \end{cases} \quad \begin{cases} -3x - 6y = 0 \\ 2x + 4y = 0 \end{cases} \\ \Rightarrow x = -\frac{3}{2}y \quad \Rightarrow x = -2y \end{array}$$

Ответ: собственные числа: $\lambda_1 = 2$, $\lambda_2 = 3$, собственные векторы: $\vec{u}_1 = \begin{pmatrix} 2 \\ -1 \end{pmatrix}$, $\vec{u}_2 = \begin{pmatrix} 3 \\ -2 \end{pmatrix}$

Матричные разложения (спектральное разложение)

Разложение матрицы - представление в виде произведения некоторых других, обладающих интересными свойствами.

Пример: спектральное разложение X

$$X = S^T \cdot D \cdot S$$



X - симметричная, S - ортогональная, D - диагональная из собственных значений X .

Часто встречаются квадратичные формы

$$f(y) = y^T X y$$

с помощью спектрального разложения приводим к более простому виду:


$$f(y) = y^T \cdot S^T \cdot D \cdot S \cdot y = (S \cdot y)^T \cdot D \cdot (S \cdot y) = z^T \cdot D \cdot z = \sum_{i=1}^n \lambda_i z_i^2,$$

Матричные разложения (сингулярное разложение)


Но это была симметричная матрица, что в случае произвольной?

$$\triangleright X = UDV$$

$\triangleright U, V$ — ортогональные, D —
диагональная



Матричные разложения (сингулярное разложение)



Сингулярное разложение представляет линейное преобразование в виде композиции: вращения, растяжения по осям, вращения.

Матричные разложения (приближение матрицей меньшего ранга)

Что такое ранг матрицы?

Матричные разложения (приближение матрицей меньшего ранга)

- Матрица задаёт отображение, ранг в какой-то степени мера “сложности” отображения
- Ранг - максимальное количество линейно независимых столбцов или строк
- Ранг - максимальный размер подматрицы с ненулевым определителем



$\text{rank}(X) \leq \min(n, m)$, если X - матрица $m \times n$

Пусть $X = AB$, A размера (m, k) , B размера (k, n)

Пусть также $k < m$, $k < n$

Что можно сказать о ранге X ?

Матричные разложения (приближение матрицей меньшего ранга)

- Матрица задаёт отображение, ранг в какой-то степени мера “сложности” отображения
- Ранг - максимальное количество линейно независимых столбцов или строк
- Ранг - максимальный размер подматрицы с ненулевым определителем



$\text{rank}(X) \leq \min(n, m)$, если X - матрица $m \times n$

Пусть $X = AB$, A размера (m, k) , B размера (k, n)

Пусть также $k < m$, $k < n$

Что можно сказать о ранге X ?

Верно! $\text{rank}(X) \leq k$

Матричные разложения (приближение матрицей меньшего ранга)

Зачем приближать матрицу матрицей меньшего ранга?

Мы предполагаем, что матрица преобразования X на самом деле более простая.

Что значит приблизить

$$\triangleright X \approx X' = UV^T$$

$$\triangleright U - m \times k, V - n \times k$$

Просто наилучшее приближение по
норме: $\|X - UV^T\| \rightarrow \min$

Матричные разложения (приближение матрицей меньшего ранга)

Что значит приблизить

$$\triangleright X \approx X' = UV^T$$

$$\triangleright U - m \times k, V - n \times k$$

Просто наилучшее приближение по
норме: $\|X - UV^T\| \rightarrow \min$

$$\|X\|_F = \sqrt{\sum_{i,j} x_{ij}^2}$$

Итоговая задача выглядит так:

$$U, V = \underset{U \in \mathbb{R}^{m \times k}, V \in \mathbb{R}^{n \times k}}{\operatorname{argmin}} \sum_{i,j} (x_{ij} - u_i^T v_j)^2$$

Матричные разложения (пример применения)

- › Пусть X – матрица признаков объектов
- › Тогда U – матрица новых признаков
- › При $k < n$ преобразование признаков понижает размерность пространства
- › По U с максимальной возможной точностью восстанавливаются исходные признаки X

Матричные разложения (пример применения)

- › Пусть X – матрица с оценками x_{ij} , поставленными пользователем i фильму j
- › Некоторые значения матрицы неизвестны
- › $x_{ij} \approx \widehat{x_{ij}} = u_i v_j$, где u_i отражает интересы пользователя, а v_j – признаковое описание фильма
- › Идея: настроим u_i и v_j на известных x_{ij} , а неизвестные спрогнозируем
- › Будем рекомендовать фильмы, для которых спрогнозирована высокая оценка

Что делать с пропущенными значениями?

Матричные разложения (пример применения)


- › Пусть X – матрица с оценками x_{ij} , поставленными пользователем i фильму j
- › Некоторые значения матрицы неизвестны
- › $x_{ij} \approx \widehat{x_{ij}} = u_i v_j$, где u_i отражает интересы пользователя, а v_j – признаковое описание фильма
- › Идея: настроим u_i и v_j на известных x_{ij} , а неизвестные спрогнозируем
- › Будем рекомендовать фильмы, для которых спрогнозирована высокая оценка

$$U, V = \underset{U \in \mathbb{R}^{m \times k}, V \in \mathbb{R}^{n \times k}}{\operatorname{argmin}} \sum_{i,j: x_{ij} \neq 0} (x_{ij} - u_i^T v_j)^2$$

Матричные разложения (связь SVD и низкорангового приближения)

$$\hat{X} = \underset{\text{rg } \hat{X} \leq k}{\text{argmin}} \|X - \hat{X}\|$$

$$X = U \cdot D \cdot V^T$$



Усечённый SVD

Матричные разложения (связь SVD и низкорангового приближения)

Оказывается, X_k - наилучшее приближение матрицы X матрицей ранга $\leq k$ по норме Фробениуса!

$$X_k = U_k D_k V_k^T$$

$$\hat{X}_k = \operatorname{argmin}_{rg(\hat{X}) \leq k} ||X - \hat{X}||_F$$

$$||X - \hat{X}||_F = \sqrt{\sum_{i,j} (x_{ij} - \hat{x}_{ij})^2}$$

Матричные разложения (рекомендательные системы)

- › Вариант 1 (не очень правильно, но просто): сделать SVD, матрицу $U_k D_k$ использовать как матрицу профилей пользователей, а матрицу V_k как матрицу профилей фильмов, произведение профилей – прогноз оценки фильма
- › Вариант 2 (более правильно, но нужно более глубоко вникнуть в метод): Не будем никак использовать SVD, а просто подберем U и V , минимизируя функционал

Спасибо за внимание!